

Clasificación de Materiales

usando Deep Learning sobre el Dataset MINC-2500

Proyecto Final · Inteligencia Artificial 2

Integrantes del Equipo

- Juan José Ardila
- Roger Fuentes

Wood

Metal

Glass

Ceramic

Foliage

Fabric

Plastic

Stone



Introducción

Contexto del Problema

La variabilidad visual de un mismo material según **iluminación, ángulo y escala**, así como la similitud entre materiales distintos.



Objetivo y Alcance

- Desarrollar un clasificador de materiales capaz de distinguir 23 categorías.
- Comparar ResNet-50, EfficientNet-B0 y Swin-Transformer.
- Evaluar generalización con métricas estándar (Accuracy, F1-Score, Precision, Recall).
- Identificar fortalezas/debilidades de cada modelo frente a materiales visualmente similares.

Dataset: MINC - 2500

Características:

- 57 500 imágenes
- 23 clases de materiales
- 2500 imágenes por clase
- tamaño $\approx$ 2.3 GB

Se encuentra dividido en:

Entrenamiento (train)

Validación (validation)

Prueba (test)





Figure 2. Example patches from all 23 categories of the **Materials in Context Database (MINC)**. Note that we sample patches so that the patch center is the material in question (and not necessarily the entire patch). See Table 1 for the size of each category.

Tomado de: <https://arxiv.org/pdf/1412.0623>

Método Propuesto — Pipeline



¿Por qué estos modelos?

ResNet-50

⚡ Robustez y estabilidad de entrenamiento

Las conexiones residuales permiten entrenar redes profundas sin degradación. Ideal como baseline sólido y bien estudiado en tareas de visión. Preentrenada en ImageNet con 50 capas convolucionales.

EfficientNet-B0

⚡ Máxima eficiencia por parámetro

Escala simultáneamente profundidad, anchura y resolución usando un coeficiente compuesto. Logra alta precisión con muchos menos parámetros, siendo ideal cuando hay restricciones de cómputo.

Swin-Transformer

⚡ Estado del arte en reconocimiento de texturas

Aplica atención mediante ventanas desplazadas (*shifted windows*), capturando relaciones de largo alcance en la imagen. Supera a las CNN en tareas donde el contexto global es esencial, como distinguir materiales con texturas similares.

ResNet-50



¿Por qué estos modelos?

EfficientNet-B0




Figure 2. Model Scaling. (a) is a baseline network example; (b)-(d) are conventional scaling that only increases one dimension of network width, depth, or resolution. (e) is our proposed compound scaling method that uniformly scales all three dimensions with a fixed ratio.

¿Por qué estos modelos?

Swin-Transformer




Figure 3. (a) The architecture of a Swin Transformer (Swin-T); (b) two successive Swin Transformer Blocks (notation presented with Eq. (3)). W-MSA and SW-MSA are multi-head self attention modules with regular and shifted windowing configurations, respectively.

Configuración Experimental



Dataset — MINC-2500

Imágenes totales 57,500

Clases de materiales 23

Muestras por clase 2,500

Tipo de imagen Patches (recortes)

Particiones Train / Val / Test

Clases: wood · metal · glass · leather · water · fabric · plastic · stone · paper · ceramic · sky · hair · foliage · brick...



Métricas de Evaluación

Accuracy — fracción total de predicciones correctas

Precision / Recall — balance entre falsos positivos y negativos

F1-Score (macro) — media armónica; crucial para 23 clases

Matriz de Confusión — identifica confusiones entre clases similares



Hiperparámetros Clave

Optimizador: Adam (lr = 0.0001)

Épocas: 10


Batch size: 32

Scheduler: StepLR (step=7, $\gamma=0.1$)

Pérdida: CrossEntropyLoss


Resultados Preliminares — Curvas de Entrenamiento

Resultados del Entrenamiento MINC-2500: Comparativa de Arquitecturas



Efecto StepLR en época 7-8: la reducción del learning rate ($\gamma=0.1$) genera un "salto" visible de mejora en los tres modelos. La validación $\geq$ entrenamiento indica ausencia de overfitting gracias al Data Augmentation aplicado.

Resultados — Comparativa en Set de Test



Modelo	Accuracy	F1-Score
ResNet-50	80.12%	0.79
EfficientNet-B0	82.00%	0.81
Swin-Transformer	85.25% 	0.85

● ResNet-50:

80.12% — sólido baseline. Confunde brick↔stone en 18 casos. Dispersión de errores más alta.

● EfficientNet-B0:

82.00% — eficiencia superior. Aprendizaje más rápido en épocas iniciales. Óptimo con recursos limitados.

● Swin-Transformer:


85.25% — diagonal limpia en matriz de confusión. F1 de wood: 0.77 vs 0.69 de ResNet.

Métricas de ResNet 50

Reporte de Clasificación (ResNet-50)

Class	Precision	Recall	F1-score	Support
brick	0.83	0.84	0.84	1000
carpet	0.84	0.86	0.85	1000
ceramic	0.72	0.75	0.73	1000
fabric	0.74	0.74	0.74	1000
foliage	0.84	0.90	0.87	1000
food	0.82	0.90	0.86	1000
glass	0.74	0.72	0.73	1000
hair	0.88	0.88	0.88	1000
leather	0.87	0.86	0.87	1000
metal	0.68	0.65	0.67	1000
mirror	0.77	0.77	0.77	1000
other	0.87	0.85	0.86	1000
painted	0.78	0.78	0.78	1000
paper	0.80	0.78	0.79	1000
plastic	0.58	0.64	0.61	1000
polishedstone	0.82	0.77	0.79	1000
skin	0.82	0.88	0.85	1000
sky	0.98	0.98	0.98	1000
stone	0.78	0.72	0.75	1000
tile	0.74	0.72	0.73	1000
wallpaper	0.85	0.90	0.88	1000
water	0.92	0.89	0.90	1000
wood	0.74	0.65	0.69	1000
accuracy	–	–	0.80	22000
macro avg	0.80	0.80	0.80	22000
weighted avg	0.80	0.80	0.80	22000

Matriz de confusión de ResNet 50




Métricas de EfficientNet B0

Reporte de Clasificación (EfficientNet-B0)

Class	Precision	Recall	F1-score	Support
brick	0.91	0.86	0.88	250
carpet	0.82	0.88	0.85	250
ceramic	0.74	0.79	0.77	250
fabric	0.78	0.72	0.75	250
foliage	0.87	0.87	0.87	250
food	0.81	0.92	0.86	250
glass	0.70	0.76	0.73	250
hair	0.91	0.91	0.91	250
leather	0.90	0.85	0.87	250
metal	0.67	0.72	0.69	250
mirror	0.80	0.79	0.79	250
other	0.90	0.86	0.88	250
painted	0.80	0.78	0.79	250
paper	0.82	0.82	0.82	250
plastic	0.70	0.64	0.67	250
polishedstone	0.80	0.74	0.77	250
skin	0.86	0.91	0.88	250
sky	0.98	0.98	0.98	250
stone	0.81	0.82	0.81	250
tile	0.71	0.76	0.73	250
wallpaper	0.91	0.88	0.90	250
water	0.94	0.93	0.94	250
wood	0.75	0.66	0.70	250
accuracy	–	–	0.82	5750
macro avg	0.82	0.82	0.82	5750
weighted avg	0.82	0.82	0.82	5750

Matriz de confusión de EfficientNet B0




Métricas de Swin-Transformer

Reporte de Clasificación (Swin-Transformer)

Class	Precision	Recall	F1-score	Support
brick	0.88	0.89	0.89	250
carpet	0.85	0.87	0.86	250
ceramic	0.83	0.83	0.83	250
fabric	0.81	0.79	0.80	250
foliage	0.94	0.93	0.93	250
food	0.87	0.94	0.90	250
glass	0.74	0.80	0.77	250
hair	0.92	0.93	0.92	250
leather	0.88	0.90	0.89	250
metal	0.72	0.74	0.73	250
mirror	0.85	0.79	0.82	250
other	0.92	0.88	0.90	250
painted	0.80	0.84	0.82	250
paper	0.86	0.86	0.86	250
plastic	0.72	0.70	0.71	250
polishedstone	0.79	0.84	0.82	250
skin	0.89	0.93	0.91	250
sky	0.98	0.98	0.98	250
stone	0.84	0.83	0.83	250
tile	0.81	0.78	0.79	250
wallpaper	0.94	0.90	0.92	250
water	0.93	0.96	0.95	250
wood	0.83	0.71	0.77	250
accuracy	-	-	0.85	5750
macro avg	0.85	0.85	0.85	5750
weighted avg	0.85	0.85	0.85	5750

Matriz de confusión de Swin-Transformer



Análisis por Clase — Héroes y Villanos

✓ Materiales Más Fáciles ($F1 > 0.90$)

sky	F1: 0.94	Color azul uniforme
water	F1: 0.92	Textura reflectante única
foliage	F1: 0.91	Verde + textura orgánica
hair	F1: 0.90	Fibras finas características

⚠ Mayor Reto — Confusión Visual

Plastic ($F1: 0.61\text{--}0.71$) — Se confunde con ceramic y glass por ser liso, brillante y reflectante.

Metal — Confusión con materiales metálicos barnizados.


Brick — ResNet confunde con stone en 18 ocasiones por textura granulada similar.

Swin-Transformer vs ResNet-50

F1-Score por clase (seleccionadas)



Estudio de Ablación:




Estudio de Ablación:

Table 6: Resultados del estudio de ablación para las diferentes configuraciones basadas en Swin Transformer. Las filas están coloreadas alternadamente para mejorar la legibilidad.


Experimento / Modelo	Pretrained	Opt.	LR	Label Smooth.	Weight Decay	Epochs	Accuracy (%)
1. swin_baseline_pro	✓	AdamW	10^{-4}	0.1	0.05	$10^{\dagger}$	0.854
2. swin_no_weights	×	AdamW	10^{-4}	0.1	0.05	$10^{\dagger}$	0.464
3. swin_simple_sgd	✓	SGD	10^{-2}	0.0	0.0	$10^{\dagger}$	0.843
4. swin_baseline_pro_long	✓	AdamW	10^{-4}	0.1	0.05	14	0.852
5. swin_simple_sgd_long	✓	SGD	10^{-2}	0.0	0.0	50	0.848

Resultados Cualitativos:


REAL: STONE
PRED: STONE




REAL: FOLIAGE
PRED: FOLIAGE



REAL: HAIR
PRED: HAIR



REAL: PAINTED
PRED: PAINTED




REAL: BRICK
PRED: BRICK




REAL: STONE
PRED: STONE



REAL: SKY
PRED: GLASS



REAL: WATER
PRED: WATER




Conclusiones



Conclusiones Actuales

- El Swin-Transformer (85.25%) supera a las CNN en clasificación de materiales gracias a su atención de contexto global.
- El StepLR demostró ser crítico: la reducción de LR en la época 7 generó la mayor mejora de todos los modelos.
- El Data Augmentation fue efectivo: ningún modelo muestra overfitting significativo ($val \geq train$).
- Los materiales reflectantes (plástico, vidrio, cerámica) siguen siendo el mayor desafío de clasificación.

Notebook Colab:



https://colab.research.google.com/drive/1Kitmy3JbimAqjbu9eJkyPHLibpLYWr_T?usp=sharing



¡Gracias!

Clasificación de Materiales con Deep Learning sobre MINC-2500

Juan José Ardila · Roger Fuentes

Inteligencia Artificial 2 · 2025

85.25%

Swin-Transformer

23

Clases

57.5K

Imágenes